Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Tím 22

Predicar - Dokumentácia inžinierskeho diela

Tímový projekt

Študijný program: ISS Inteligentné softvérové systémy

Vedúci projektu: Ing. Miroslav Rác

Členovia tímu: Branislav Baláž, Peter Bokor, Max Karel Dávid, Ondrej Harnúšek, Richard Letanec, Veronika Vejčíková, Tomáš Vrtal

November 2019

1. Úvod

Tento dokument opisuje realizáciu nášho zadania v rámci predmetu Tímový projekt na tému “Predikcia ceny vozidla na základe inzerátu [CarAd]”. Projekt vyvíjame pod názvom Predicar a ide o produkt, ktorý má na základe textu inzerátu odhadnúť cenu vozidla a poskytnúť iné užitočné štatistiky alebo odhady spojené práve s predajom daného vozidla.

1.1 Hlavný cieľ na zimný semester

“**Chceme vidieť vypočítanú predikciu ako odhad ceny v našom rozhraní pre štandardný vstup.**”

2. Základná štruktúra systému

V tejto kapitole ponúkneme náhľad na nami navrhnutú architektúru systému. Okrem toho zhrnieme aj dátový model, podľa ktorého uchovávame v našom systéme dáta o vozidlách a jednotlivých inzerátoch.

2.1 Architektúra

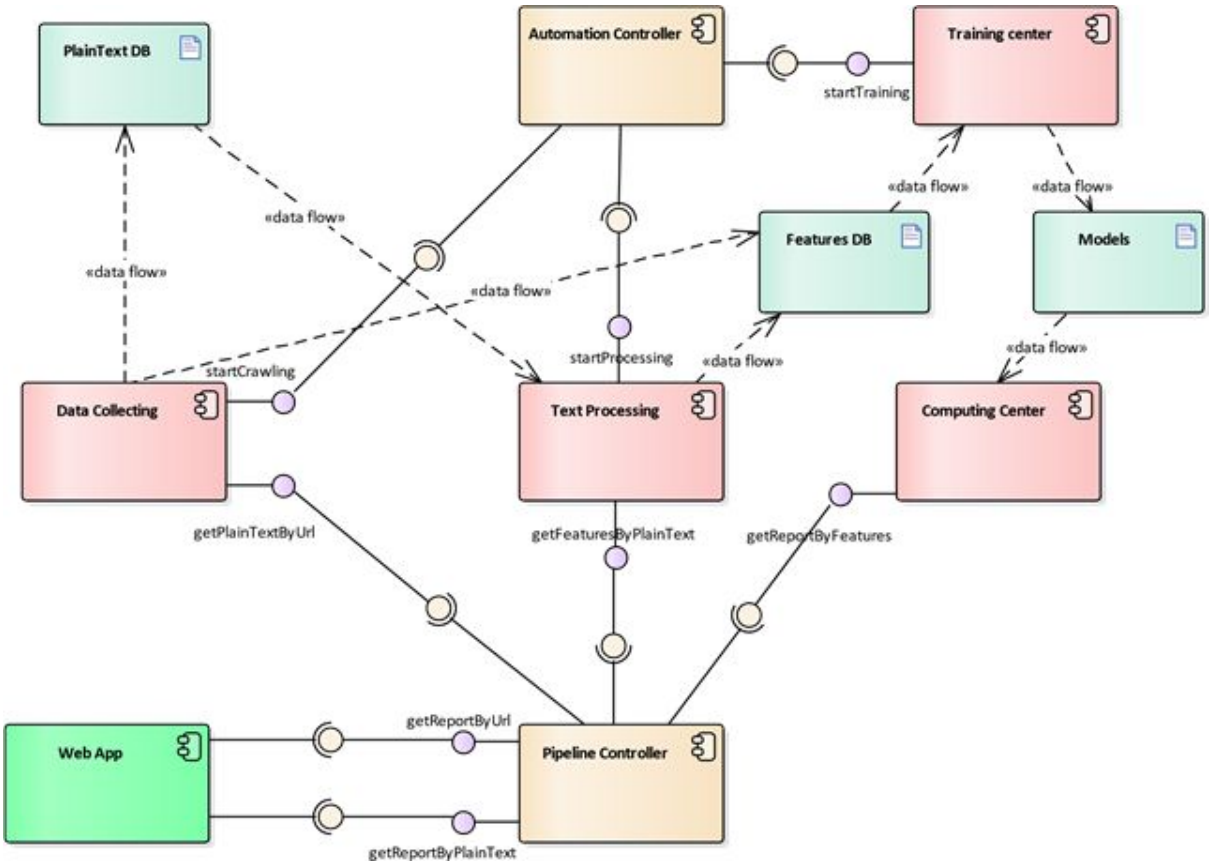

Obrázok 1 Základný pohľad na architektúru systému Predicar

Náš systém je zameraný na strojové učenie, pomocou čoho dokáže odhadnúť ceny vozidiel. Kvôli tomuto si architektúra vyžaduje časť zameranú na **zber dát**. Tieto dáta potom uchovávame v dokumentovej databáze.

Strojové učenie sa v našej architektúre objavuje v dvoch inštanciách: **spracovanie textu** pre extrakciu čŕt z textu inzerátu a samotný **model pre odhad cien**. Zatiaľ čo spracovanie textu nepotrebujeme sústavne trénovať, ak dokáže správne interpretovať texty inzerátov, odhad cien musíme pravidelne trénovať, aby odhady cien vždy brali do úvahy aktuálne dáta. Preto je súčasťou našej architektúry aj **trénovacie centrum**.

Interakcia so systémom je zabezpečená cez jednoduché **webové rozhranie.** Pomocou tohto rozhrania môže používateľ zadať odkaz na inzerát alebo jeho samotný text a pozrieť sa na odhady a štatistiky od nášho produktu.

Okrem týchto častí musíme pre systém zabezpečiť aj iné **riadiace moduly,** ktoré sú znázornené na obrázku 2.

2.2 Dátový model

Dátový model nášho systému pozostáva z jednej entity, keďže sme zvolili dokumentovú databázu ako úložisko našich dát. Tieto dáta odrážajú vlastnosti vozidla a kolekciu inzerátov, ktoré sa naň vzťahujú. Údaje, ktoré o vozidlách uchovávame sú nasledovné:

- **VIN**: VIN číslo predstavuje unikátny identifikátor vozidla
- **licence_plate**: zoznam ŠPZ značiek pre vozidlo s daným VIN číslom
- **price**: výsledná cena vozidla agregovaná z cien nájdených v inzerátoch pre dané vozidlo
- **features**: vlastnosti vozidla, ktorých presný zoznam určíme pri zbere dát
- **ads**: zoznam objektov s nasledovnou štruktúrou, ktoré reprezentujú nájdené inzeráty pre vozidlo:
    - **url**: unikátny odkaz na inzerát
    - **version**: verzia inzerátu
    - **created_at**: čas vytvorenia inzerátu
    - **ad_price**: cena uvedená v inzeráte
    - **sold**: dátum predaja alebo prázdna hodnota, ak ešte predané nebolo
    - **ad_features**: vlastnosti vozidla získané z daného inzerátu
    - **parsed_raw_text**: znenie inzerátu
    - **raw_html**: html obsah stránky s inzerátom

2.3 Zoznam priložených elektronických dokumentov

- **GUI Design Document** - Návrh rozhrania webovej stránky pre interakciu so systémom
- **Structure of Components** - Prehľad architektúry a správania komponentov

3. Popis modulov

3.1 Data Collection

Analýza	Produkt si vyžaduje, aby sme vždy pracovali s aktuálnymi dátami. Preto potrebujeme zabezpečiť neustály zber dát z viacerých portálov na predaj áut cez inzerát.
Návrh	Časť systému zodpovedná za zber dát sa skladá z viacerých komponentov: ● Processing queue - udržiava odkazy na inzeráty, ktoré treba spracovať ● New URL Discovery - objavuje nové odkazy na inzeráty ● Data Updater - aktualizuje stav inzerátov v databáze ● Downloader - stiahne obsah stránky ● Parser - vytiahne zo stránky znenie inzerátu
Implementácia	Zber dát, teda crawler, je implementovaný ako mikroslužba volaná riadiacim modulom. Jazyk: Python

3.2 Text Processing

Analýza	Pre spracovanie textu potrebujeme vhodnou metódou implementovaný model pre spracovanie textu v slovenčine. Modul Text processor bude do databázy ukladať nájdené črty, cez ktoré budeme môcť trénovať predikčný model.
Návrh	Pre spracovanie jazyka v slovenčine sú pre nás relevantné 2 možnosti: slovníková metóda a strojové učenie s použitím word2vec.
Implementácia	Text processing je implementovaný ako mikroslužba volaná riadiacim modulom. Jazyk: Python

3.3 Training Center

Analýza	Model pre odhad cien musí vždy odrážať aktuálny stav trhu, preto musíme zabezpečiť, že tento model sa bude pravidelne učiť na aktuálnych dátach. Toto trénovanie chceme spúšťať v pravidelných intervaloch.

3.4 Computing Center

Analýza	Pre odhad cien je potrebný regresný model, ktorý pomocou strojové učenia dokáže tieto odhady generovať. Okrem toho potrebujeme iné modely, aby sme získali dáta pre vizualizácie zhrnuté v priloženom elektronickom dokumente.
Návrh	Natrénované modely máme uložené v pamäti, pričom ich trénovaním získané váhy uchovávame v databáze.
Implementácia	Výpočtové centrum je implementované ako mikroslužba volaná riadiacim modulom. Jazyk: Python

3.5 Web App

Analýza	Pre intuitívnu interakciu so systémom chceme implementovať používateľské rozhranie vo forme webovej stránky, ktorá poskytne prehľadnú časť, kam používateľ môže zadať samotné znenie alebo odkaz na inzerát vozidla. Potom mu taktiež musí prezentovať vypočítané dáta.
Návrh	Návrh rozhrania webovej stránky nájdete medzi priloženými elektronickými dokumentmi.